

## ANÁLISIS DE UNA SECUENCIA USANDO HERRAMIENTAS DISPONIBLES EN LA RED

Samuel Pintos González

### **1. SELECCIÓN DE LA SECUENCIA E IDENTIFICACIÓN DE ORFs**

He utilizado “ORF finder” para el primer ejercicio, copiando la secuencia proporcionada en esa página web con los parámetros por defecto, salvo en la sección “ORF start codon to use”, ya que como no sé a qué organismo pertenece la secuencia, he seleccionado “ATG and alternative initiation codons”

Elijo ORF1 [Figura 1] ya que encapsula al resto de ORFs en la secuencia y es el más grande.

### **2. ANÁLISIS FUNCIONAL DE LA SECUENCIA**

La secuencia de aminoácidos que viene dada en la propia herramienta de “ORF finder” al seleccionar el ORF1 es:

MNYSFTEKKRIRKSFAKRENVLEVPFLLATQIDSYAKFLQLENAFDKRTDDGLQAAFNSIFPIVSHNGYARLE  
FVYTLGEPLFDIPECQLRGITYAAPLRARIRLVILDKEASKPTVKEVRENEVYMGEIPLMTPSGSFVINGTER  
VIVSQLHRSPGVFFEHDKGKTHSSGKLLFSARIIPYRGSWLDfefDPKDLYFRIDRRRKMPVTILLKALGYN  
NEQILDIFYDKETFYLSSNGVQTDLVAGRLKGETAKVDILDKEGNVLVAKGKRITAKNIRDITNAGLRLDVE  
QESLLGKALAADLIDSETGEVLASANDEITEELLAKFINGVKEITTLYINELDQGAYISNTLRTDEAGRQAA  
RVAIYRMMMRPGEPPTEAVEQLFNRLFFSEDSYDLSRVGRMKFNRTYEQKLSEAQQNSWYGRLLNETF  
AGAADKGGVLSVEDIVASIATLVELRNNGHGEVDDIDHLGNRRVRSGELTENQFRSGLARVERAVKERLN  
QAESENLMPHDLINAKPVSAAIKEFFGSSQLSQMDQTNPLSEVTHKRRVSALPGGLTRERAGFEVRDV  
HPTHYGRVCPIETPEGPNIGLINSVYARTNDYGFLETPYRRVIDGKVTEEIDYLSAIEEGRYVIAQANADL  
DSDGNLIGDLVTCREKGETIMATPDRVQYMDVATGQVVSVAAASLIPFLEHDDANRALMGANMQRQAVP  
CLRPEKPMVGTIERSVAVDSATAIVARRGGVVEYVDANRVVIRVHDDEATAGEVGVDIYNLVKFTRSNQS  
TNINQRPAVKAGDVLQRGDLVADGASTDLGELALGQNMTIAFMPWNGNYEDSILISEKVAADDRTSI  
HIEELNVVARDTKLGAEDITRDIPNLSEMQNRLDESGIVYIGAEVEAGDVLVGKVTPKGETQLTPEEKLLR

AIFGEKASDVKDTSLRMPTGMSGTVIDQVVFREGIQRDKRAQSIIIDSELKRYRLDLNDQLRIFDNDAFDR  
IERMIVGQKANGGPMKLAGSEITTEYLAGLPSRHDWFDIRLTDEDLAKQLELIKLSLQQKREEADELYEIK  
KKKLTQGDELQPGVQKMKVVFIAKRRHQAGDKMAGRHNKGVVSRILPVEDMPYMADGRPVDIVLP  
LGVPNSRMNIGQILEVHLGWAAGIGERIDRMLKERRKAGELREFLNKLYNGSGKKEDLDSLTDDEEIELASN  
LRKGASFASPVFDGAKESEIREMLNLAYPSEDPEVEKLGFNDSKTQITLYDGRSGEAFDRKVTGVMHYLK  
LHHLVDEKMHARSTGPYSLVTQQPLGGKAQFGGQRFGEMEVWALEAYGAAYTLQEMLTVKSDDVNGR  
TKMYENIVKGEHKIDAGMPESFNVLVKEIRSLGLDIDLERY

Copio la secuencia de aminoácidos en protein BLAST seleccionando la base de datos “Reference proteins (refseq\_protein)”. A continuación me aparece que su cobertura es el 100% de la secuencia con un porcentaje de identidad del 100% y un E-valor de 0.0 [Figura 2]. Pertenece a la especie *Neisseria gonorrhoeae*, donde la descripción de esta proteína sería “DNA-directed RNA polymerase subunit beta”.

Con core nucleotide database (core nt) para el nucleotide blast, me aparece la misma cobertura, E-valor y porcentaje de identidad pero con descripciones distintas una de otra, a pesar de que el organismo coincide también [Figura 3].

### 3. COMPARACIÓN EVOLUTIVA

[WP\\_003690105.1](#) *Neisseria gonorrhoeae* (el organismo al que pertenece la secuencia)

[WP\\_119518745.1](#) *Pseudomonas aeruginosa*

[WP\\_353524646.1](#) *Escherichia coli*

[Figura 4].

Haciendo el alineamiento a 3Bits para ser más estrictos que a 2Bits, las 2 regiones que tienen una conservación más grande (en cuanto a longitud de la cadena de amino ácidos sin variaciones) entre estos 3 organismos, siendo estas para *Neisseria gonorrhoeae* son:

aminoácido 527 al 603 y aminoácido 1260 al 1361. Hay varias regiones donde faltan datos (en gris, siendo la más grande la del aminoácido 420 al 444) y hay diferentes regiones bastante variables [Figura 5].

#### **4. ANÁLISIS ESTRUCTURAL**

Utilizando la herramienta PROSITE, introduzco la secuencia de aminoácidos que me dio ORFfinder.

Obtengo un dominio proteico entre los aminoácidos 1104 y 1116 (correspondiendo al código “PS01166” y con la serie de aminoácidos “GDKMAGRHGNKGV”), el cual coincide con una zona muy conservada entre el organismo de la secuencia y el resto de organismos del alineamiento (aunque no está dentro de las zonas conservadas más grandes que se han destacado previamente).

Según los datos aportados por la propia herramienta seleccionando la secuencia conservada, contiene dos lisinas muy bien conservadas que son parte del sitio activo del extremo C-terminal de todas las cadenas beta y este sería el motivo por el que varía tan poco entre especies.

## ANEXO: IMÁGENES DE APOYO AL TRABAJO Y SU DESCRIPCIÓN




Figura 1. Representación de ORFfinder de todos los ORFs de la secuencia seleccionada en barras horizontales rojas, siendo ORF1 el primero y el más grande, abarcando al resto de ORFs

Query Cover	E value	Per. Ident	Acc. Len	Accession
100%	0.0	99.93%	1392	<a href="#">WP_404518383.1</a>
100%	0.0	99.93%	1392	<a href="#">WP_218422894.1</a>
100%	0.0	100.00%	1392	<a href="#">WP_003690105.1</a>

Figura 2. Resultados del análisis por protein BLAST de la secuencia de aminoácidos que se ha obtenido previamente con ORFfinder

	Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain 9035 chromosome_complete genome</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2223133	<a href="#">CP104546.2</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae isolate G97687 genome assembly_chromosome_1</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2174841	<a href="#">LS999565.1</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain 10538 chromosome_complete genome</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2223795	<a href="#">CP104548.2</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain AT159 chromosome_complete genome</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2232771	<a href="#">CP097846.1</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain TH2288 chromosome_complete genome</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2227834	<a href="#">CP138339.1</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain CT530 chromosome_complete genome</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2169323	<a href="#">CP048254.1</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain JS-23-24 chromosome_1_complete sequence</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2231116	<a href="#">CP195874.1</a>
<input checked="" type="checkbox"/>	<a href="#">Neisseria gonorrhoeae strain WHO K genome assembly_chromosome_1</a>	<a href="#">Neisseria gonorrhoeae</a>	7718	7718	100%	0.0	100.00%	2169846	<a href="#">LT591908.1</a>

Figura 3. Nucleotide BLAST donde se analiza la secuencia de nucleótidos obtenida del enunciado del ejercicio donde aparece la especie a la que pertenece (*Neisseria gonorrhoeae*) y distintos valores como su cobertura y porcentaje de identidad.




Figura 4. Selección de 3 organismos distintos para hacer un alineamiento. Las barras rojas horizontales indican zonas conservadas entre estos organismos, mientras que los espacios se deben a zonas variables o desconocidas

Sequence ID	Start	End	Description
WP_003690105_1	1	80	MNYSFTEKKIRKSFAKRENVLEVFPLLATQIDSYAKFLQLENAFDKRTDDGLQAAAFNSIFPIVSHNGYARLEFVYYTLG
WP_119518745_1	1	80	MAYSYTEKKIRKDFSKLPDVMDPVYLAIQLDSYREFLQAGATKEQFRDIGLHAAFKSVFPIISYSGNAALEYVGYRLG
WP_353524646_1	1	76	MVYSYTEKKIRKDFGKRPKVLDPYLSIQLDSQFKIEQDPEQG----YLEAARFSVFPQSYSGNSELQYVSYRLG
WP_003690105_1	81	160	EPLDFIPPECQLRGTYAAPLRARIVRLVILDEAKSPTVKVEVRENEVYMEIPLTSGSFVINGTERVIVSQLHRSPGVF
WP_119518745_1	81	160	EPAFDVKECVLRGVTFAVPLRKVLRLVYEREAPEGTVKDIKEQEVYMEIPLMTNGTFVINGTERVIVSQLHRSPGVF
WP_353524646_1	77	156	EPVFDVQECQIRGVTVSAPLVRKLRLVYEREAPEGTVKDIKEQEVYMEIPLMTNGTFVINGTERVIVSQLHRSPGVF
WP_003690105_1	161	240	FEHDKGKTHSSGKLLFSARIPIYRGSWLDFFEDPKDLYFRRDRRKMPVTILLKALGYNNEQILDIFYDKEFYLSNG
WP_119518745_1	161	240	FDHDRGKTHSSGKLLYSARIPIYRGSWLDFFEDPKDCVFRRIDRRRKLPASVLLRALGYSTEELNAFYATNVFH1KGET
WP_353524646_1	157	236	FDSOKGKTHSSGKVLYNARIPIYRGSWLDFFEDPKDNLFRRIDRRRKLPATIILRALNYTTEQILDFFEKVIFEIRDNK
WP_003690105_1	241	320	VQTDLVAGRLKGETAKVDILDKEGNVLVAKGKRITAKNIRDITNAGLTRLDVQESLLGKALAADLIDSETGEVLASAND
WP_119518745_1	241	320	LNLLEVPLQRGEVASIDIKDGSCKVIVEQGRRIATARHINQLEKAGVSQLEPVDFYLRGTTIAKAZVHPATGEIIACNT
WP_353524646_1	237	315	LQMELVPERLRLGETASFDT-EANGKVYVEKGRRIATARHQLKEKDDVKLIEVPVEIAGKVVAKDYIDESTGELICAAM
WP_003690105_1	321	400	EITEELLAKEGETINGVKEITLTLYNLDQGAYISNTLRTDETAGRQAARVAIYRMRMPEPTEAAVEQLFNRLLFFSEDSY
WP_119518745_1	321	400	ELTLIDLAKVAKAQVVRRIETLTNDICGPFISDFTLKIINTSNQLEALVEIYRMRMPEPPTKEAAETLFGNLFSAERY
WP_353524646_1	316	395	ELSLDLALAKLSQSGHKRITELFTNDLHDGPYISETLVDPTNDRQSLAVEIYRMRMPEPPTREAESLFENLFFSEDRY
WP_003690105_1	401	498	DLSAVGRMKFNTRTYEQL [22] KGGYVLSVEDIVASIATLVELRNHGHEVDDIDHLGNRNRVRSVGETENQFRSLARV
WP_119518745_1	401	476	DLSAVGRMKFNRRIGRTEI EGPGVLSKEDIIDIVLKTLVDIRNGKGIVVDDIDHLGNRNRVCVGEAENQFRVGLRV
WP_353524646_1	396	471	DLSAVGRMKFNRSLLREEI EGSGILSKDDIDIVMKKLIDIRNGKGIVVDDIDHLGNRNRIRSVGEMAENQFRVGLRV
WP_003690105_1	499	578	ERAVKERLNQASESENLMPHDILNAKPSAAIKEEFFGSSQLSQFMQDQTNPLSEVTKRRVSALGPGGLTRERAGFEVRDVH
WP_119518745_1	477	556	ERAVKERLMSAESEGLMPQDLINAKPVAAIKEEFFGSSQLSQFMQDQNPPLSEITHKRRVSALGPGGLTRERAGFEVRDVH
WP_353524646_1	472	551	ERAVKERLSDLQGDLDLMPQDMINAKPISAAVKEEFFGSSQLSQFMQDQNPPLSEITHKRRISALGPGGLTRERAGFEVRDVH
WP_003690105_1	579	658	PTHYGRVCPIETPEGPNIGLINSVYARTNDYGFLETPTYRVIDGKVTLEEIDYLSAIEEGRYVIAQANADLSDGMLIG
WP_119518745_1	557	636	PTHYGRVCPIETPEGPNIGLINSLATYRINKVGFLESPTYRVKDSLVTDEIYVIAAEEADHVIQASATLNEKGQLVD
WP_353524646_1	552	631	PTHYGRVCPIETPEGPNIGLINSVYATQNEGFLETPTYRVIDGVTDEIYLSAIEEGNYVIAQANSNLDEEGHFVE
WP_003690105_1	659	738	DLVTCREKGGETIMATPDRVQYMDVATGQVSVVASLIPFLEHDDANRALMGANMQRQAVPCLRPEKPMVGTGERSVAVD
WP_119518745_1	637	716	ELVAVRHLNEFTVKAPEDVTLMDSVSPKQVSVVASLIPFLEHDDANRALMGNSMQRQAVPTLRADKPLVGTGMERNVARD
WP_353524646_1	632	711	DLVTCRSKGESSLFSRDQVYDIDVSTQQVSVGASLIPFLEHDDANRALMGANMQRQAVPTLRADKPLVGTGMERAVID
WP_003690105_1	739	818	SATAIVARRGGVVEYVDANRVRIRHVHDEATAGEVGVDIYNLVKFTRSNQSTNIQNRAVAKAGDVLLQRGDVLAQGASTDL
WP_119518745_1	717	796	SGVCVARRGGVVIDSVDSRVRVVRADDEVETGEAGVDIYNLTKYTRSNQNTCINORPLVSKGDVVARGDILADGPSTD
WP_353524646_1	712	791	SGVTAVAKRGGVQQYDASRIVIKVNEADEMYPGEAGIDIYNLYKTRSNQNTCINQMPCVSLGEPPERGDVLAQGASTDL
WP_003690105_1	819	898	GELALGQNMINTIAFMPWNGYNYEDSILISEKVAADDRTSIHIEELNVVARDTKLGAEDIITDIPNLSERMQNRLDESGIV
WP_119518745_1	797	876	GELALGQNMIRVAFMPWNGNFNEDSICLISERVQEDRFTTIHQIELTCVARDTKLGEPEITADIPNVGEAALNLKDEAGIV
WP_353524646_1	792	871	GELALGQNMIRVAFMPWNGYNYFEDSILVSERVQEDRFTTIHQIELACVSRDTKLGEPEITADIPNVGEAALSKLDESGIV
WP_003690105_1	899	978	YIGAEVAGDVLVGKVTPKGETQLTPEEKLLRAIFGEKASDVKDTSLRMPTGMSGTVIDQVFTREGIQRDKRAQSIIIDS
WP_119518745_1	877	956	YVGAEVQAGDILVGKVTPKGETQLTPEEKLLRAIFGEKASDVKDTSLRVPTGTKGTVIDQVFTRDGVRSRALSIEM
WP_353524646_1	872	951	YIGAEVTTGDDILVGKVTPKGETQLTPEEKLLRAIFGEKASDVKDSSLRVPNGVSGTVIDQVFTRDGVKEDKRALEIEEM
WP_003690105_1	979	1056	ELKRYRLDLDQLRIFDNDAFDIERMIVG[4]GGPMK--LAKGSEITTEYLAGLPsRHDWFDIRLTOEDELAKQLELIK
WP_119518745_1	957	1032	QLDQTRKDLNEEFRIVEGATFERLRLAALVG AKAEQGpaLKKGEITEIDYLDGLE-RQWFKLRMADDALNEQLEKAQ
WP_353524646_1	952	1015	QLKQAKKDLSEEQILEAGLFSRIRAVLVA GGVEA-----EKLDKL-PDRWL-EGLTDEEKQNQLEQLA
WP_003690105_1	1057	1136	LSLQQKREEADEYLICKKKLTLQGDELQPGVQKMVKVFIAIKRRQLAGDKMAGRHNKGVSVRLPVEDMPYADGRPV
WP_119518745_1	1033	1112	AYISDRQLLDKFKRKLQGDDLAPGVLKIVKVLPAIJKRQIOPGDKMAGRHNKGVSVIMPVEDMPHDANGTPV
WP_353524646_1	1016	1095	EQYDELKHEFEKKLEAKRRKITQGDDLAPGVLKIVKVLPAVLRKRQIOPGDKMAGRHNKGVISKINPIEDMPYDENGTPV
WP_003690105_1	1137	1213	IVLNPLGVPSRMMNIQOILEVHLGWAAKGIGERIDRMLKERRAGELREFLNKLYN--GSGKKEDDLDSLDEEEILASN
WP_119518745_1	1113	1190	IVLNPLGVPSRMMNVQGQILETHLGLAAGLGEKINRMLEEQRKVAELRKFLHEIYN-GIGGREG-NLDELGDNEILALAKN
WP_353524646_1	1096	1175	IVLNPLGVPSRMMNIQOILETHLGMAKGIGDKINMLKQQQEVALKREFIQRAYD1GADVRQKVDSLTSDEEVMLAEN
WP_003690105_1	1214	1301	LRKGASFASPVFDGAKESIREML[12]KLGFDNSKTQITLYDGRSGEAFDRKVTGVMHYLKLHHLVDEKMHARSTGPY
WP_119518745_1	1191	1266	LRGGVPMATPVFDGAKERIKAML KLADLPESGQIQLRFDGRGTFNQERPTVGYMMMLKLNHLVDDKMHARSTGSY
WP_353524646_1	1176	1251	LRKGMPATPVFDGAKAEIKELL KLGDLPTSGQIRLYDGRTEQEFPRTVGYMMMLKLNHLVDDKMHARSTGSY
WP_003690105_1	1302	1381	SLVTQQPLGGKAQFGGQRFGEIMEVWALEAYGAAYTLQEMLTVKSDDVNGRTKMYENIVKGEHKIDAGMPESFNVLK
WP_119518745_1	1267	1346	SLVTQQPLGGKAQFGGQRFGEIMEVWALEAYGAAYTLQEMLTVKSDDVNGRTKMYKNIVDGDHRMAGMPESFNVLK
WP_353524646_1	1252	1331	SLVTQQPLGGKAQFGGQRFGEIMEVWALEAYGAAYTLQEMLTVKSDDVNGRTKMYKNIVDGNHQMEPGMPESFNVLK
WP_003690105_1	1382	1392	SLGLDIDLER
WP_119518745_1	1347	1357	SLGIDIELETE
WP_353524646_1	1332	1342	SLGINIELEDE

Figura 5. Alineamiento de los 3 organismos seleccionados donde se representan los aminoácidos conservados (rojo), las zonas variables (azul) y las zonas desconocidas (gris).